



**CAMPUS
VERDE**
Universidad de Nariño



SGR
SISTEMA GENERAL DE REGALAS

Más para Todos

**DESARROLLO DE UN MODELO ALTERNATIVO DE ENERGÍA Y MOVILIDAD CON FUENTES NO
CONVENCIONALES EN LA UNIVERSIDAD DE NARIÑO**
BPIN 2020000100041

Evento de verano

CAMPUS VERDE UDENAR

Avances de Investigación en Energía y Movilidad





**CAMPUS
VERDE**
Universidad de Nariño



Más para Todos

Inferencia Estadística Clásica y Bayesiana: Introducción a la Estimación de Parámetros

Carlos Andrés Viteri Mera
Profesor Asociado
Departamento de Electrónica
Universidad de Nariño



Contenido

- ▶ Motivación
- ▶ Inferencia estadística clásica
- ▶ Inferencia estadística bayesiana
- ▶ Conclusiones





**CAMPUS
VERDE**

Universidad de Nariño

Motivación


- ▶ Un conjunto de **parámetros desconocidos** se desea estimar a partir de unas **mediciones que incluyen incertidumbre**.
- ▶ La incertidumbre puede ser causada por factores internos del sistema (e.g., ruido eléctrico) o factores externos (e.g., mediciones manuales).
- ▶ Se cuenta con información estadística del proceso.



$$X \sim \mathcal{N}(5, 9)$$

Motivación

- ▶ ¿El parámetro Θ es determinístico (fijo y desconocido) o una variable aleatoria?
 - ▶ La inferencia clásica (o frecuentista) trata Θ como un parámetro determinístico.
 - ▶ La inferencia bayesiana trata Θ como una variable aleatoria.
- ▶ ¿Qué información estadística se necesita en cada caso?



Inferencia clásica:

$$f_X(x; \theta)$$

Inferencia bayesiana:

$$f_{\Theta}(\theta)$$

$$f_X(x)$$

$$f_{X|\Theta}(x|\theta)$$

$$f_{\Theta|X}(\theta|x)$$

Contenido

- ▶ Motivación
- ▶ Inferencia estadística clásica
- ▶ Inferencia estadística bayesiana
- ▶ Conclusiones




**CAMPUS
VERDE**

Universidad de Nariño

Inferencia clásica

- La inferencia clásica trata θ como un parámetro determinístico (fijo y desconocido).



- El sistema está completamente caracterizado por la **función de verosimilitud** (*likelihood*).

Ejemplo:

$$X = \theta + W$$

$$W \sim \mathcal{N}(0, \sigma^2)$$

$$X \sim \mathcal{N}(\theta, \sigma^2)$$

$$f_X(x; \theta) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \theta)^2}{2\sigma^2}\right)$$

Se asume que σ es conocido

Estimador de máxima verosimilitud

- Teniendo un conjunto de mediciones $\mathbf{x} \in \mathbb{R}^n$, el estimador de máxima verosimilitud (ML, *maximum likelihood*) del parámetro se obtiene como

$$\hat{\theta}_{ML} = \arg \max_{\theta} f_X(\mathbf{x}; \theta),$$

o también

$$\hat{\theta}_{ML} = \arg \max_{\theta} \ln(f_X(\mathbf{x}; \theta)).$$

- $\ln(f_X(\mathbf{x}; \theta))$ se conoce como la función de log-verosimilitud (*log-likelihood*).

Estimador de máxima verosimilitud

- Ejemplo 1: tomemos el modelo $X = \theta + W$, donde θ es el parámetro desconocido y $W \sim \mathcal{N}(0,1)$. Se obtienen varias mediciones **independientes** de la forma $x_i = \theta + w_i$ y se conforma el vector

$$\mathbf{x} = [x_1, x_2, \dots, x_5]^T = [5.65, 10.03, 7.73, 6.94, 7.71]^T.$$

- La función de verosimilitud en este caso es

$$f_X(\mathbf{x}; \theta) = (2\pi)^{-n/2} |\sigma^2 \mathbf{I}_n|^{-1/2} \exp\left(-\frac{1}{2} (\mathbf{x} - \theta \mathbf{1})^T (\mathbf{x} - \theta \mathbf{1})\right)$$


- El estimador de máxima verosimilitud es

Parámetro verdadero $\theta = 7$

$$\hat{\theta}_{ML} = \arg \max_{\theta} \ln(f_X(\mathbf{x}; \theta)) = \frac{x_1 + x_2 + x_3 + x_4 + x_5}{5} = 7.61$$

Estimador de máxima verosimilitud

- Ejemplo 2: un sistema de comunicaciones se modela como $\mathbf{x} = \theta \mathbf{a} + \mathbf{w}$, donde $\mathbf{a}$ es un vector de entrenamiento conocido por el transmisor y el receptor, $\mathbf{w} \sim \mathcal{N}(0, 0.1\mathbf{I})$ es el ruido y θ es la atenuación del canal.




- La función de verosimilitud en este caso es

$$f_X(\mathbf{x}; \theta) = (2\pi)^{-n/2} |0.1\mathbf{I}_n|^{-1/2} \exp\left(-\frac{1}{0.2} (\mathbf{x} - \theta \mathbf{a})^T (\mathbf{x} - \theta \mathbf{a})\right)$$

- El estimador de máxima verosimilitud es

$$\hat{\theta}_{ML} = \arg \max_{\theta} \ln(f_X(\mathbf{x}; \theta)) = \frac{\mathbf{a}^T \mathbf{x}}{\mathbf{a}^T \mathbf{a}}$$

Estimador de máxima verosimilitud



$$\hat{\theta}_{ML} = \frac{a^T x}{a^T a} = 0.7111$$

Parámetro
verdadero
 $\theta = 0.7$

Contenido

- ▶ Motivación
- ▶ Inferencia estadística clásica
- ▶ Inferencia estadística bayesiana
- ▶ Conclusiones




**CAMPUS
VERDE**

Universidad de Nariño

Inferencia bayesiana

- La inferencia bayesiana trata Θ como un parámetro aleatorio.



- Está basada en el teorema de Bayes. Para variables aleatorias discretas:

$$p_{\Theta|X}(\theta|x) = \frac{p_{\Theta}(\theta)p_{X|\Theta}(x|\theta)}{\sum_{\theta'} p_{\Theta}(\theta')p_{X|\Theta}(x|\theta')}$$

Inferencia bayesiana

The Four Versions of Bayes' Rule

- Θ discrete, X discrete:

$$p_{\Theta|X}(\theta | x) = \frac{p_{\Theta}(\theta)p_{X|\Theta}(x | \theta)}{\sum_{\theta'} p_{\Theta}(\theta')p_{X|\Theta}(x | \theta')}.$$

- Θ discrete, X continuous:

$$p_{\Theta|X}(\theta | x) = \frac{p_{\Theta}(\theta)f_{X|\Theta}(x | \theta)}{\sum_{\theta'} p_{\Theta}(\theta')f_{X|\Theta}(x | \theta')}.$$

- Θ continuous, X discrete:


$$f_{\Theta|X}(\theta | x) = \frac{f_{\Theta}(\theta)p_{X|\Theta}(x | \theta)}{\int f_{\Theta}(\theta')p_{X|\Theta}(x | \theta') d\theta'}.$$

- Θ continuous, X continuous:

$$f_{\Theta|X}(\theta | x) = \frac{f_{\Theta}(\theta)f_{X|\Theta}(x | \theta)}{\int f_{\Theta}(\theta')f_{X|\Theta}(x | \theta') d\theta'}.$$

Inferencia bayesiana


- ▶ La inferencia clásica trata Θ como un parámetro aleatorio.




- ▶ La caracterización estadística es más dispendiosa:
 - ▶ $f_{\Theta}(\theta)$ es el *prior* o pdf *a priori*.
 - ▶ $f_X(x)$ es la pdf marginal.
 - ▶ $f_{X|\Theta}(x|\theta)$ es la **verosimilitud**.
 - ▶ $f_{\Theta|X}(\theta|x)$ es la pdf *a posteriori* o posterior .

Inferencia bayesiana

- pdfs *a priori* utilizadas frecuentemente:



Normal



Laplace

- Algunas distribuciones *a priori* (impropias) pueden afectar la interpretación de los resultados o incluso la integrabilidad en la regla de Bayes (e.g., la pdf uniforme).

El estimador *a posteriori*

- En forma similar al de máxima verosimilitud, el estimador *maximum a posteriori* (MAP) se define como

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} p_{\Theta|X}(\theta | x), \quad \text{si } \theta \text{ es discreta.}$$

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} f_{\Theta|X}(\theta | x), \quad \text{si } \theta \text{ es continua.}$$

- Debido a la capacidad de combinar variables continuas y discretas, estos estimadores se usan comúnmente para pruebas de hipótesis o toma de decisiones.

El estimador *a posteriori*

- Un sistema de comunicaciones se modela como $x = \theta + w$, donde $w \sim \mathcal{N}(0, I)$ es el ruido y θ es una señal transmitida que puede tomar valores $\theta_0 = [-1, -1, 1, 1]^T$ o $\theta_1 = [-1, 1, -1, 1]^T$ que ocurren con probabilidades $p_{\theta}(\theta_0) = p_{\theta}(\theta_1) = 0.5$. Dada la medición x , ¿cuál es el estimador MAP de θ ?

- Las verosimilitudes son

$$f_{\mathbf{X}|\theta}(\mathbf{x} | \theta = \theta_0) = (2\pi)^{-n/2} |\sigma^2 \mathbf{I}|^{-1/2} \exp \left(-\frac{1}{2} (\mathbf{x} - \theta_0)^T (\sigma^2 \mathbf{I})^{-1} (\mathbf{x} - \theta_0) \right).$$

$$f_{\mathbf{X}|\theta}(\mathbf{x} | \theta = \theta_1) = (2\pi)^{-n/2} |\sigma^2 \mathbf{I}|^{-1/2} \exp \left(-\frac{1}{2} (\mathbf{x} - \theta_1)^T (\sigma^2 \mathbf{I})^{-1} (\mathbf{x} - \theta_1) \right).$$

El estimador *a posteriori*

- Al aplicar la regla de Bayes se obtiene



$$p_{\boldsymbol{\theta}|X}(\boldsymbol{\theta} = \boldsymbol{\theta}_0 | \mathbf{x}) = \frac{1}{1 + \exp \left[\frac{1}{2\sigma^2} (2\mathbf{x}^T \boldsymbol{\theta}_1 - 2\mathbf{x}^T \boldsymbol{\theta}_0 + \boldsymbol{\theta}_0^T \boldsymbol{\theta}_0 - \boldsymbol{\theta}_1^T \boldsymbol{\theta}_1) \right]},$$

$$p_{\boldsymbol{\theta}|X}(\boldsymbol{\theta} = \boldsymbol{\theta}_1 | \mathbf{x}) = \frac{1}{1 + \exp \left[\frac{1}{2\sigma^2} (2\mathbf{x}^T \boldsymbol{\theta}_0 - 2\mathbf{x}^T \boldsymbol{\theta}_1 + \boldsymbol{\theta}_1^T \boldsymbol{\theta}_1 - \boldsymbol{\theta}_0^T \boldsymbol{\theta}_0) \right]}.$$


- Para saber qué posterior es mayor se realiza la prueba

$$\mathbf{x}^T (\boldsymbol{\theta}_0 - \boldsymbol{\theta}_1) \underset{H_1}{\overset{H_0}{\gtrless}} \frac{\|\boldsymbol{\theta}_0\|_2^2 - \|\boldsymbol{\theta}_1\|_2^2}{2}$$

El estimador *a posteriori*



**CAMPUS
VERDE**
Universidad de Nariño



- En este caso, la regla MAP selecciona θ_0 (correcta).
- Se comenten tres errores en un millón de transmisiones.

Estimador de mínimo error cuadrático medio


- El estimador de mínimo error cuadrático medio (MMSE, *minimum mean squared error*) se puede utilizar en los mismos casos que el ML, agregando información en el *prior*.

$$\begin{aligned}\hat{\theta}_{\text{MMSE}} &= \arg \min_{\hat{\Theta}} \mathbf{E} \left[(\Theta - \hat{\Theta})^2 | X = x \right] \\ &= \mathbf{E}[\Theta | X = x].\end{aligned}$$

- En muchos casos, no tiene una forma cerrada y deben calcularse algunas integrales o sumatorias numéricamente:

$$\mathbf{E}[\Theta | X = x] = \int_{-\infty}^{\infty} \theta f_{\Theta|X}(\theta, x) d\theta.$$

Conclusiones

- 
- ▶ La inferencia estadística nos permite estimar parámetros en todo tipo de sistemas y con variables continuas o discretas.
 - ▶ La inferencia es altamente dependiente del modelo. Por lo tanto, funciona muy bien en sistemas con información estructurada (e.g., sistemas de comunicaciones).
 - ▶ La inferencia bayesiana utiliza información del parámetro (*a priori*) para mejorar la estimación, pero su complejidad (de análisis y computacional) es mayor.



**CAMPUS
VERDE**
Universidad de Nariño



SGR
SISTEMA GENERAL DE REGISTROS

Más para Todos

¡Gracias!

Carlos Andrés Viteri Mera
Profesor Asociado
Departamento de Electrónica
Universidad de Nariño
Primer Líder GIIEE
caviteri@udenar.edu.co

