

Introducción a la Ciencia de Datos

Semana 07: Procesos ARMA y el Filtro de Wiener

Carlos A. Viteri Mera
Profesor Titular
Departamento de Electrónica



Universidad de **Nariño**

Marzo de 2026

Contenido

Procesos ARMA

Filtro óptimo de Wiener

Contenido

Procesos ARMA

Filtro óptimo de Wiener

Estacionariedad en Sentido Amplio

Un proceso estocástico x es estacionario en sentido amplio (WSS, *wide sense stationary*) si se satisfacen las tres condiciones siguientes:

- El valor esperado del proceso es constante (independiente de n) $\mu_x(n) = \mu_x$.
- Su función de autocorrelación $r_x(n_1, n_2)$ solamente depende de la diferencia $n_2 - n_1$.
- La varianza del proceso es finita, es decir, $c_x(0) < \infty$.

Estacionariedad Conjunta y Propiedades

Los procesos estocásticos x , y son *conjuntamente estacionarios* si su correlación cruzada satisface:

$$\begin{aligned}r_{xy}(n_1, n_2) &= r_{xy}(n_2 - n_1) \\&= \mathbf{E}\{x(n_1)y(n_2)\} \\&= \mathbf{E}\{x(n)y(n + n_1)\} \\&= r_{xy}(n)\end{aligned}$$

donde $n = n_2 - n_1$. La función de autocorrelación del proceso WSS x satisface:

- Simetría: $r_x(n) = r_x(-n)$.
- Valor medio cuadrado: $r_x(0) = \mathbf{E}\{[x(n)]^2\}$.
- Valor máximo: $\max_n r_x(n) = r_x(0)$.

Generación de Procesos ARMA

Los procesos ARMA son aquellos que se generan al filtrar ruido blanco con un filtro lineal invariante en el tiempo.

- El ruido blanco $v(n)$ es un proceso estocástico en tiempo discreto, caracterizado por tener media cero y muestras no correlacionadas.
- Su función de autocovarianza es un impulso: $c_v(k) = \sigma_v^2 \delta(k)$, donde σ_v^2 es la varianza del ruido.
- Al pasar este ruido $v(n)$ por un filtro, obtenemos procesos con estructuras de correlación complejas (como los mercados financieros).

Proceso de Promedios Móviles - MA(q)

Un proceso de Promedios Móviles (Moving Average) de orden q , denotado como MA(q), se genera al filtrar ruido blanco con un filtro FIR (Finite Impulse Response).

La ecuación en diferencias que define el proceso $x(n)$ es:

$$x(n) = \sum_{k=0}^q b_q(k)v(n-k)$$

- $v(n)$ es el ruido blanco de entrada.
- $b_q(k)$ son los parámetros del modelo.
- El valor actual $x(n)$ es una combinación lineal de las perturbaciones (ruido) actuales y pasadas.

Proceso Autorregresivo - AR(p)

Un proceso Autorregresivo de orden p , denotado como AR(p), se genera al filtrar ruido blanco con un filtro IIR (Infinite Impulse Response) de la forma *sólo-polos*.

La ecuación que lo rige es:

$$x(n) + \sum_{k=1}^p a_p(k)x(n-k) = b(0)v(n)$$

- $a_p(k)$ son los coeficientes autorregresivos.
- El valor actual $x(n)$ depende linealmente de sus propios p valores pasados, más una perturbación aleatoria actual $v(n)$.

Proceso ARMA(p, q)

Al combinar ambas estructuras, obtenemos el proceso Autorregresivo de Promedios Móviles, denotado como ARMA(p, q).

La relación lineal entre el ruido $v(n)$ y la salida $x(n)$ es:

$$x(n) + \sum_{l=1}^p a_p(l)x(n-l) = \sum_{l=0}^q b_q(l)v(n-l).$$

- Modela dinámicas temporales complejas utilizando menos parámetros que un modelo AR o MA puro.
- En el dominio z , su función de transferencia $H(z)$ contiene p polos y q ceros.
- Asumiendo que el filtro es estable, el proceso de salida $x(n)$ será estacionario en sentido amplio (WSS).

Contenido

Procesos ARMA

Filtro óptimo de Wiener

Matriz de Autocorrelación

Sea $\mathbf{x} = [x(0), x(1), \dots, x(p)]^\top$ un vector con $p+1$ valores del proceso estocástico. Entonces,

$$\mathbf{x}\mathbf{x}^\top = \begin{bmatrix} x(0)x(0) & x(0)x(1) & \cdots & x(0)x(p) \\ x(1)x(0) & x(1)x(1) & \cdots & x(1)x(p) \\ \vdots & \vdots & \ddots & \vdots \\ x(p)x(0) & x(p)x(1) & \cdots & x(p)x(p) \end{bmatrix},$$

es una matriz $(p+1) \times (p+1)$. Tomando el valor esperado, se llega a la *matriz de autocorrelación* del proceso dada por

$$\mathbf{R}_x = \mathbf{E}\{\mathbf{x}\mathbf{x}^\top\} = \begin{bmatrix} r_x(0) & r_x(1) & \cdots & r_x(p) \\ r_x(1) & r_x(0) & \cdots & r_x(p-1) \\ r_x(2) & r_x(1) & \cdots & r_x(p-2) \\ \vdots & \vdots & \ddots & \vdots \\ r_x(p) & r_x(p-1) & \cdots & r_x(0) \end{bmatrix}.$$

El Filtro de Wiener

El filtro de Wiener es un filtro óptimo diseñado para resolver problemas de estimación al minimizar el error cuadrático medio entre la salida del filtro y una señal deseada.

- A diferencia de otros filtros, requiere el conocimiento de las propiedades estadísticas (densidad espectral de potencia o autocorrelación) de los procesos involucrados.
- Asume que los procesos que se están filtrando son estacionarios en sentido amplio (WSS).
- Una de sus aplicaciones más importantes es la **predicción lineal**, donde la señal deseada es un valor futuro del mismo proceso.

Predicción Lineal

En la predicción lineal, buscamos estimar el valor actual (o futuro) de una señal $x(n)$, denotado como $\hat{x}(n)$, utilizando una combinación lineal de sus p valores pasados.

El estimador se define como:

$$\hat{x}(n) = \sum_{k=1}^p a_k x(n-k)$$

- a_k son los coeficientes de predicción lineal (o coeficientes del filtro).
- El error de predicción es la diferencia entre el valor real y el estimado:
 $e(n) = x(n) - \hat{x}(n)$.
- El objetivo del filtro de Wiener es encontrar los coeficientes a_k que minimicen el error cuadrático medio $\mathbf{E}[|e(n)|^2]$.

El Principio de Ortogonalidad

Para minimizar el error cuadrático medio, los coeficientes óptimos deben satisfacer el **principio de ortogonalidad**.

Este principio establece que el error de estimación óptimo debe ser ortogonal a los datos utilizados para la estimación. Matemáticamente:

$$\mathbf{E}[e(n)x^*(n-k)] = 0 \quad ; \quad k = 1, 2, \dots, p$$

- Al sustituir $e(n) = x(n) - \sum_{l=1}^p a_l x(n-l)$ en esta ecuación, la minimización se transforma en un problema de álgebra lineal.

Ecuaciones de Wiener-Hopf (Ecuaciones Normales)

Al aplicar el principio de ortogonalidad, llegamos a un conjunto de p ecuaciones lineales con p incógnitas conocidas como las ecuaciones normales o ecuaciones de Wiener-Hopf:

$$\sum_{l=1}^p a_l r_x(k-l) = r_x(k) \quad ; \quad k = 1, 2, \dots, p$$

En forma matricial, esto se expresa de manera concisa como:

$$\mathbf{R}_x \mathbf{a} = \mathbf{r}_x$$

- $\mathbf{R}_x$ es la matriz de autocorrelación (simétrica y Toeplitz) de tamaño $p \times p$.
- $\mathbf{r}_x$ es el vector de correlación cruzada.
- La solución $\mathbf{a} = \mathbf{R}_x^{-1} \mathbf{r}_x$ proporciona los coeficientes óptimos del filtro predictor de Wiener.

Bibliografía

- Monson Hayes, *Statistical Digital Signal Processing and Modeling*, Wiley, 1996.